

Подход к созданию банковского Research Assistant

Концепция безопасного внутреннего Deep Research для банковских аналитиков на основе рыночного анализа и ограничений банковской среды

Executive Summary

Банковское ограничение принципиально меняет подход: решение нельзя строить как простой внешний чат-бот или обертку над публичным LLM API. Нужен закрытый research-конвейер, который можно развернуть внутри банковского контура и подключить к разрешенной LLM-платформе: AlfaGen, локальной Gemma, GigaChat on-prem, GPT-OSS-подобной модели или другой внутренней модели.

Ключевая бизнес-формулировка: безопасный внутренний Deep Research для банковских аналитиков, работающий с открытыми источниками, но не раскрывающий внутренние данные банка наружу.

Целевые принципы

- Data boundary: наружу уходят только обезличенные поисковые запросы по публичной теме; внутренние документы, стратегии, клиентские данные и финальные отчеты остаются внутри контура.
- Auditability: каждый важный вывод должен быть связан с конкретным источником, датой, типом источника и уровнем доверия.
- Model-agnostic design: система не должна зависеть от одной модели; LLM подключается через единый gateway и может быть заменена без переписывания конвейера.
- Human-in-the-loop: аналитик утверждает отчет и интерпретации; система помогает собирать и структурировать информацию, но не принимает бизнес-решения сама.
- Compliance-aware collection: приоритет у API, RSS, официальных документов, отчетов и разрешенных источников; агрессивный обход антибот-защиты не является целью продукта.

Целевая архитектура

Слой	Назначение
UI / API / Notebook	Точка входа для аналитика: тема, география, период, тип источников, формат результата.
Классификатор чувствительности	Проверяет, нет ли в запросе внутренней или клиентской информации, которую нельзя отправлять наружу.
Research Planner	Разбивает тему на поисковые подзадачи: определения, кейсы, vendor-solutions, academic papers, риски, метрики.
Source Collector	Собирает открытые источники через Search API, RSS, официальные сайты, PDF, отчеты и fallback-рендеринг.
Parser / Cleaner	Извлекает текст из HTML/PDF, убирает навигацию, рекламные блоки, повторы и мусор.

Слой	Назначение
Domain Filter / Reranker	Отбирает релевантные материалы с помощью BM25, embeddings и финансового NLP-классификатора.
Evidence Store	Хранит источники, очищенные фрагменты, ссылки, даты, типы источников, score доверия и версии отчета.
LLM Synthesizer	Формирует аналитическую записку строго по найденным фрагментам и внутренним правилам банка.
Fact Checker / Critic	Проверяет наличие источников у утверждений, противоречия, выдуманные цифры и слабые выводы.

MVP: что нужно реализовать первым

- 1 Research Planner: принимает тему и превращает ее в план исследования. Например, для CLTV: use cases, модели расчета, кейсы банков, риски, метрики, vendors.
- 2 Source Collector: собирает 30-100 кандидатов из открытых источников. Для демо можно начать с API или заранее подготовленного списка надежных источников.
- 3 Noise Filter: удаляет SEO-мусор, дубли, нерелевантные новости, рекламные страницы и материалы без содержательных фактов.
- 4 Domain Classifier: ранжирует материалы по релевантности именно банковской аналитике, а не просто совпадению ключевых слов.
- 5 Evidence Store: сохраняет источники и фрагменты так, чтобы любой вывод можно было проверить.
- 6 LLM Synthesizer: пишет отчет: краткое резюме, кейсы, таблица источников, выводы, unknowns и рекомендации для дальнейшей проверки.
- 7 Quality Gate: отдельный проход проверяет, что отчет не содержит неподтвержденных утверждений и что все ключевые тезисы имеют ссылки.

Оценка предложенных технических идей

Идея	Как применять	Важное ограничение
FinBERT	Использовать как дешевый доменный фильтр / классификатор релевантности перед дорогим LLM-синтезом.	Классический FinBERT в основном англоязычный и часто заточен под financial sentiment; для РФ-источников нужны multilingual/ruBERT-подходы или дообучение.
curl_cffi	Быстрый HTTP-клиент для публичных страниц, где нужен browser-like fingerprint и стабильная загрузка.	Не должен превращаться в механизм обхода ограничений сайтов; в банковском pitch лучше делать акцент на легитимный сбор.
Playwright	Fallback для JS-страниц, PDF/HTML-рендеринга, скриншотов и проверки доступности источников.	Дороже и медленнее простого HTTP; применять после API/RSS/http-загрузки.
CloakBrowser	Можно изучить как подход, но не ставить в ядро банковского решения.	Anti-bot bypass выглядит юридически и репутационно рискованно для банка.
huggingface/ml-intern	Использовать как архитектурный референс: agentic loop, tools, approval checks, local model endpoints.	Не тащить runtime как есть: внешние токены, provider-интеграции и trace-upload не подходят банковскому контуру без аудита.
Локальная Gemma / внутренняя LLM	Подключать через LLM gateway как пример on-prem модели; архитектуру держать совместимой с AlfaGen и другими внутренними моделями.	Модель должна работать по найденным evidence-фрагментам, а не свободно генерировать выводы без ссылок.

Рекомендуемый стек для прототипа

- Backend: FastAPI.
- Orchestration: LangGraph или простой собственный state machine.
- Search: Yandex Search API, Tavily, SerpAPI или mock-слой для демо.

- Fetching: httpx / curl_cffi, fallback Playwright.
- Parsing: BeautifulSoup, trafilatura, rypdf, при необходимости Jina Reader.
- Storage: PostgreSQL + pgvector или Qdrant.
- LLM gateway: OpenAI-compatible endpoint, за которым может быть Gemma, AlfaGen, GigaChat или внутренняя модель.
- UI: Streamlit для быстрого MVP или простой React/FastAPI интерфейс.

Банковские требования, которые важно подчеркнуть

- Изоляция данных: внутренние материалы банка не отправляются во внешние LLM/API.
- Контроль запросов: система проверяет, нет ли в поисковом запросе клиентских данных, внутренних названий проектов, стратегий или чувствительных показателей.
- Журналирование: сохраняются запросы, источники, версии отчета, модель, параметры генерации и пользовательские правки.
- Объяснимость: отчет обязан содержать evidence table и раздел unknowns, чтобы бизнес видел границы уверенности.
- Замена модели: LLM является заменяемым компонентом; это позволяет говорить, что в MVP используется локальная Gemma, а в банковском внедрении может использоваться AlfaGen.
- Правовой контур сбора данных: приоритет у открытых официальных источников, отчетов, API, RSS и разрешенного web-доступа.

Демо-сценарий: CLTV в иностранных банках

Для демонстрации лучше выбрать тему CLTV, потому что она одновременно понятна бизнесу и хорошо раскрывает пользу системы. Research assistant должен собрать, отфильтровать и структурировать материалы по следующим блокам:

- зачем банкам CLTV: удержание, персонализация, cross-sell, приоритизация маркетинговых бюджетов;
- как считают CLTV: будущая маржа, retention probability, продуктовая корзина, каналные расходы, риск дефолта;
- какие данные нужны: транзакции, продукты, кампании, обращения, цифровое поведение, риск-профиль;
- как применяют: next best action, сегментация, удержание ценных клиентов, управление CAC/LTV;
- какие есть риски: privacy, bias, explainability, ошибочная дискриминация низкомаржинальных клиентов.

Метрики качества MVP

Метрика	Что показывает
Precision@K по источникам	Доля действительно релевантных источников в топе выдачи.
Citation accuracy	Доля утверждений, корректно подтвержденных источниками.
Hallucination rate	Доля тезисов, которые не подтверждаются evidence store.
Noise reduction	Какая доля мусорных/дублирующих материалов удалена до LLM-синтеза.
Time to brief	Сколько времени занимает подготовка первой аналитической записки.
Human acceptance rate	Доля отчетов, которые аналитик принимает без существенной переработки.

Дорожная карта

Этап	Результат
1. Notebook MVP	Конвейер поиска, парсинга, фильтрации и генерации отчета по одной теме CLTV.
2. Web/API MVP	Простой интерфейс, очередь задач, evidence table, экспорт отчета.
3. Bank-ready prototype	LLM gateway, policy checks, логирование, роли пользователей, настройки источников.
4. Enterprise integration	Интеграция с внутренней LLM-платформой, DLP/ИБ-контуром, корпоративным хранилищем и SSO.

Финальная формулировка для защиты

Мы предлагаем безопасный исследовательский ассистент для банковских команд. Он автоматизирует первичный сбор и структурирование открытой информации, но сохраняет банковские данные внутри закрытого контура, работает через локальную или корпоративную LLM-платформу и выдает проверяемый отчет с источниками, confidence и списком неопределенностей.

Сильная сторона проекта не в том, что он просто использует FinBERT, Gemma или Playwright, а в банковски зрелой архитектуре: безопасность, интеграция, аудит, заменяемость моделей, управляемый сбор источников и проверяемость результата.